

Шпаргалка по вычислительной математике

Построение QR-разложения матрицы QR-разложение матрицы A — её представление в виде $A = QR$, где Q — ортогональная, R — верхняя треугольная матрица.
Преобразования Хаусхолдера Исходная матрица A имеет размерность $m \times m$.

1. x_1 — первый столбец матрицы A : $x_1 = (a_{11}, a_{21}, \dots, a_{m1})^T$. Построим вектор $v_1 = x_1 + \|x_1\|e_1$ и матрицу Хаусхолдера H_1 на основе v_1 . Векторы x_1, v_1, e_1 имеют размерность m , а H_1 — размерность $m \times m$. Ортогональная матрица $U_1 = H_1$. Умножим матрицу A слева на U_1 . Первый столбец полученшей матрицы приобретает вид первого столбца верхней треугольной матрицы (свойство преобразования Хаусхолдера).

2. Построим вектор x_2 размерности $m - 1$ как второй столбец матрицы $U_1 A$ без первого элемента: $x_2 = (a_{22}^*, a_{32}^*, \dots, a_{m2}^*)^T$, $v_2 = x_2 + \|x_2\|e_1$, где e_1 — столбец единичной матрицы E размерности $m - 1$. Матрица Хаусхолдера H_2 на основе v_2 имеет размерность $(m - 1) \times (m - 1)$. Ортогональная матрица U_2 размерности $m \times m$, первая строка и столбец которой совпадают с E , а остальные элементы равны H_2 :

$$U_2 = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & H_2 & & & \\ 0 & & & & \\ \vdots & & & & \\ 0 & & & & \end{pmatrix}$$

Умножая $U_1 A$ справа на U_2 , обеспечиваем два столбца верхней треугольной матрицы:

$$U_1 U_2 A = \begin{pmatrix} * & * & * & * & * \\ 0 & * & * & * & * \\ 0 & 0 & * & * & * \\ 0 & 0 & 0 & * & * \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & * \end{pmatrix}$$

Данный процесс позволяет получить верхнюю треугольную матрицу R за $m - 1$ шагов:

$$(U_{m-1} U_{m-2} \dots U_1 U_0) A = R; \quad A = QR;$$

$$Q = (U_{m-1} U_{m-2} \dots U_1 U_0)^{-1} = (U_{m-1} U_{m-2} \dots U_1 U_0)^T = U_0^T U_1^T \dots U_{m-1}^T.$$

Ортогональность матрицы Q следует из симметричности и ортогональности матриц U_k .

Сингулярное разложение матрицы.

Сингулярным разложением матрицы $A \in R^{m \times n}$ с вещественными элементами называется её представление в виде $A = U \sum V^T$, $U U^T = E_m$, $V V^T = E_n$.

U-ортогональная матрица $(m \times m)$ V-ортогональная матрица $(n \times n)$, $\sum$ — диагональная матрица $(m \times n)$ с элементами σ_{kj} $= 0$ при $k \neq j$

1. Определение сингулярного разложения (SVD)

Для произвольной вещественной матрицы $(A \in R^{m \times n})$, сингулярное разложение имеет вид: $A = U \Sigma V^T$,

где: $(U \in R^{m \times m})$, $(V \in R^{n \times n})$ — ортогональные матрицы; $(\Sigma \in R^{m \times n})$ — диагональная матрица с неотрицательными элементами σ_k на диагонали; $\sigma_k \geq 0$ — сингулярные числа матрицы A . 2. Связь сингулярных чисел с $A^T A$ и $A A^T$

Рассматриваются две симметричные матрицы: $-A^T A = V \Sigma^T \Sigma V^T$.

$$A A^T = U \Sigma \Sigma^T U^T.$$

Таким образом, собственные значения этих матриц равны квадратам сингулярных чисел σ_k^2 . Если $m \geq n$, то $A^T A$ имеет n ненулевых собственных значений (равных σ_k^2), а остальные — нулевые.

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}; \quad \Sigma^T = \begin{pmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix};$$
$$\Sigma^T \Sigma = \begin{pmatrix} \sigma_1^2 & 0 & 0 & 0 \\ 0 & \sigma_2^2 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}; \quad \Sigma \Sigma^T = \begin{pmatrix} \sigma_1^2 & 0 & 0 & 0 \\ 0 & \sigma_2^2 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix};$$

3. Эффективный ранг и обусловленность
- Ранг матрицы равен числу ненулевых сингулярных чисел. - Эффективный ранг — число (σ_k) , удовлетворяющих $(\sigma_k > \epsilon)$, где (ϵ) — уровень машинной точности или допустимой погрешности.
- Число обусловленности: $cond(A) = \sigma_{max} \sigma_{min}^{-1}$. 4. Построение SVD
Реализуется двумя этапами: 1. Приведение к леводиагональной форме с помощью преобразований Хаусхолдера. 2. QR-алгоритм для диагонализации леводиагональной матрицы и получения Σ .
Программа "SVD" Выход: SVDNM, M, N, A, W, MATU, U, MATV, V, IERR, RV1
Параметры: - 'A' — исходная матрица A ; - 'U' — 'V' — выходные ортогональные матрицы; - 'W' — сингулярные числа; - 'IERR' — код завершения; - 'RV1' — вспомогательный вектор; - 'MATU', 'MATV' — логические параметры, определяющие необходимость вычисления 'U' и 'V'.
6. Применение в методе наименьших квадратов

При решении $Ax \approx f$, заменяют A на $U \Sigma V^T$ и получают:
 $\Sigma c' \approx f'$, $c' = V^T c$, $f' = U^T f$.
Задача сводится к решению: $-\sigma_k c'_k = f'_k$ — если $\sigma_k \neq 0$, $f'_k \approx 0$ — если $\sigma_k = 0$.

Решение дается в виде: $c_{opt} = \sum_{k=1}^r f'_k \sigma_k v_k$, где v_k — столбцы матрицы V , а r — эффективный ранг. 7. Повышение устойчивости
Если $\sigma_k < \epsilon$, соответствующие члены опускаются, уменьшая чувствительность решения к шуму в данных. Это повышает стабильность, но увеличивает невязку $\|Ax - f\|$.

QR-алгоритм
Грубая схема Обозначим $A_0 = A$. На шаге с номером k выполняется QR-разложение матрицы A_k . Затем матрицы Q_k и R_k перемножаются в обратном порядке для получения A_{k+1} . При этом матрицы A_k и A_{k+1} оказываются подобными, т.е. собственные значения исходной матрицы в результате такого преобразования сохраняются
Описание базового QR-алгоритма Для произвольной невырожденной матрицы $A_0 \in R^{n \times n}$ алгоритм заключается в решениях $A_k = Q_k R_k$, $A_{k+1} = R_k Q_k$, где Q_k — ортогональная, а $Q_k^T A_k Q_k$ — верхнетреугольная матрицы из QR-разложения A_k . Поскольку $A_{k+1} = R_k^T A_k Q_k$, все матрицы A_k подобны исходной, и при $k \rightarrow \infty$ последовательность сходится к верхнетреугольному (или кваитреугольному) виду, на диагонали которого стоят собственные значения A_0 . а $A_{ij} = 0$ для всех $i > j$

Уменьшение числа итераций: применение сдвигов На каждом шаге выбирается приближение сдвига τ_k (например, диагональный элемент $a_{nn}^{(k)}$), и проводит QR-разложение матрицы $A_k - \tau_k I$: $A_k - \tau_k I = Q_k R_k$, $A_{k+1} = R_k Q_k + \tau_k I$. Такой сдвиг ускорит сходимость к одному из собственных значений, особенно при близких корнях. **Сокращение объема вычислений на каждом шаге** за счет последовательных преобразований Хаусхолдера или Гивенса матрицу A_0 приводят к верхнетреугольно-полублочному виду (Хессенберговой форме) за $O(n^3)$. Все последующие QR-шаги сохраняют эту форму, и один шаг QR-итерации требует $O(n^2)$ операций вместо $O(n^3)$. Пусть матрица A_0 имеет форму Хессенберга

$$A_0 = \begin{pmatrix} * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \\ 0 & 0 & 0 & * \end{pmatrix}$$

Тогда $Q_0 = A_0 R_0^{-1}$ имеет такой же вид.

$$Q_0 = A_0 R_0^{-1} = \begin{pmatrix} * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \\ 0 & 0 & 0 & * \end{pmatrix}$$

Умножая в обратном порядке убедимся, что A_1 сохраняет форму A_0

$$A_1 = R_0 Q_0 = \begin{pmatrix} * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \\ 0 & 0 & 0 & * \end{pmatrix}$$

Использование сингулярного разложения матрицы

$$\begin{matrix} x & x_1 & x_2 & x_3 & x_n \\ f(x) & f(x_1) & f(x_2) & f(x_3) & f(x_n) \end{matrix} \quad \text{Аппроксимация } f: Q_{n-1}(x) =$$

$c_1 \varphi_1(x) + c_2 \varphi_2(x) + \dots + c_n \varphi_n(x) = \sum_{k=1}^n c_k \varphi_k(x)$ (1)
Коэффициенты c_k определяются из условия минимума квадрата расстояния между $Q_{n-1}(x)$ и $f(x)$:

$$\rho^2 = (Q_{n-1}(x) - f(x), Q_{n-1}(x) - f(x)) \quad (2) \text{ Необходимое}$$

условие экстремума: $\frac{\delta \rho^2(c_k)}{\delta c_k} = 0$, $k = 1, 2, \dots, n$ приводит к системе линейных алгебраических уравнений, которая с ростом числа исковых коэффициентов становится катастрофически плохо обусловленной. Более надежно сингулярное разложение матрицы. Попытка максимально удачно описать табличную функцию с помощью $Q_{n-1}(x)$ приводит к: $A \approx f$, $c = (c_1, c_2, \dots, c_n)^T$, $f = (f(x_1), f(x_2), \dots, f(x_m))^T$ где элементы прямоугольной $m \times n$ матрицы A определяются по формулам: $a_{ik} = \varphi_k(x_i)$, $i = 1, 2, \dots, m$, $k = 1, 2, \dots, n$. Вектор невязки $r = A c - f$. Минимизация его длины: $(r, r) \rightarrow \min(0)$ полностью совпадает с задачей минимизации ρ^2 . Будем искать c , чтобы квадрат длины вектора невязки был минимален. Заменяя в (3) матрицу A её сингулярным разложением $U \Sigma V^T$ и умножая на U^T , получаем: $\Sigma V^T c \approx U^T f \Rightarrow \tilde{c} = V^T c$, $\tilde{f} = U^T f$, $c = V \tilde{c}$, $f = U \tilde{f}$ (4) $\Sigma \tilde{c} \approx \tilde{f}$ (5) Вектор невязки: $\tilde{r} = \Sigma \tilde{c} - \tilde{f}$ Длина осталась прежней.

Решение (5):
1 случай: $m \geq n$
Две подсистемы: $\tilde{c}_k \rho_k^2 \approx \tilde{f}_k$, $k = 1, 2, \dots, n$ (6)
 $0 \approx \tilde{f}_k$, $k = m + 1, \dots, m$ (7) Сингулярные числа упорядочены по убыванию. Если $m = n$, подсистема (7) отсутствует. Минимум ρ^2 и условие (0) из (6) решается точно $(\sigma_k \neq 0): \tilde{c}_k = \frac{\tilde{f}_k}{\sigma_k}$, $k = 1, 2, \dots, n$ (8)
 $\min(\rho^2) \Rightarrow (r, r) = (\tilde{r}, \tilde{r}) = \sum_{k=n+1}^m \tilde{f}_k^2$ (9)

2 случай: $m < n$
Все сингулярные числа не нулевые, подсистема (7) отсутствует. Из (6): $\tilde{c}_k \sigma_k = \tilde{f}_k$, $k = 1, 2, \dots, m$ Первые m значений выбираются из условия: $\tilde{c}_k = \frac{\tilde{f}_k}{\sigma_k}$, $k = 1, 2, \dots, m$ Остальные $\tilde{c}_k$ выбираются произвольно.

Преобразование Гивенса
Преобразование Гивенса называется преобразованием с матрицей (1) (матрицей вращения). Эта матрица отличается от единичной четырьмя элементами, стоящими на пересечении двух строк и столбцов k и j : $t_{kk} = t_{jj} = c$, $t_{jk} = -t_{kj} = s$, $c^2 + s^2 = 1$. Перемножая, можно понять, что матрица ортогональна: $T_{kj}^{-1} = T_{kj}^T$, $T_{kj}^T \cdot T_{kj} = E$.

$$T_k = \begin{pmatrix} 1 & & & & \\ & \dots & & & \\ & c & \dots & \dots & -s \\ & s & \dots & \dots & c \\ & & & & 1 \\ & & & & \dots & c \\ & & & & & & 1 \end{pmatrix} \quad (1)$$

Действие:

1. Пусть $A_{(k)}$ — k -й столбец A , $A_{(k)}$ — k -я строка матрицы. Умножим A на T_{kj} ($B = A T_{kj}$). Матрицы A и B отличаются двумя столбцами: $B_{(k)} = c A_{(k)} + s A_{(j)}$, $B_{(j)} = -s A_{(k)} + c A_{(j)}$.

2. Матрицу T_{kj}^T умножим на B ($G = T_{kj}^T B$). Матрицы G и B отличаются двумя строками: $G_{(k)} = c B_{(k)} + s B_{(j)}$, $G_{(j)} = -s B_{(k)} + c B_{(j)}$. Обозначим элементы матрицы G как g_{ps} . Для $1 < j < k$ выберем s и c так, чтобы $g_{k,j-1} = 0$: $g_{k,j-1} = c b_{k,j-1} + s b_{j,j-1} = c a_{k,j-1} + s a_{j,j-1}$.

3. Столбец $(j - 1)$ в A и B один и тот же. Выполняя $g_{k,j-1} = 0$, получаем следующие: $\frac{g}{c} = -\frac{a_{k,j-1}}{a_{j,j-1}}$, $c = \frac{a_{j,j-1}}{\sqrt{a_{k,j-1}^2 + a_{j,j-1}^2}}$, $s = -\frac{a_{k,j-1}}{\sqrt{a_{k,j-1}^2 + a_{j,j-1}^2}}$.

Последовательное применение таких вращений приводит матрицу к форме Хессенберга.

Псевдообратная матрица Мура-Пенроуза

A^+ —, $x = A^+ b$ Если A имеет полный столбцовый ранг, то: $A^+ = (A^T A)^{-1} A^T$ (r, r) = $(A x - b, A x - b) = (A x, A x) - 2(A x, b) + (b, b) = (A^T A x, x) - 2(x, A^T b) + (b, b) \rightarrow \min$ Необходимое условие минимума: $\frac{\delta(r,r)}{\delta x} = 2 A^T A x - 2 A^T b = 0$ $x = (A^T A)^{-1} A^T b = A^+ b$, $A^+ = (A^T A)^{-1} A^T$
Псевдообратной матрицей Мура-Пенроуза называется матрица $X = A^+$, удовлетворяющая 4 условиям: $A X A = A$, $X A X = X$, $A X$ — симметричная $X A$ — симметричная. Можно показать, что такая матрица X существует и единственна, и для её построения применяется сингулярное разложение.

$$\sigma^+ = \begin{cases} \frac{1}{\sigma}, & \text{если } \sigma \neq 0 \\ 0, & \text{если } \sigma = 0 \end{cases}$$

Для $A = \sigma (1 \times 1)$ определить X как $X = \sigma^+$ — все 4 условия выполняются. В общем случае для $\Sigma (m \times n): \Sigma^+ (n \times m) \Rightarrow X = A^+ = V \Sigma^+ U^T$

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}; \quad \Sigma^+ = \begin{pmatrix} \sigma_1^{-1} & 0 & 0 & 0 \\ 0 & \sigma_2^{-1} & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}; \quad \text{и т.д.}$$
$$U^T = \begin{pmatrix} \sigma_1^{-1} & 0 & 0 & 0 \\ 0 & \sigma_2^{-1} & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}; \quad V = \begin{pmatrix} \sigma_1^{-1} & 0 & 0 & 0 \\ 0 & \sigma_2^{-1} & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}; \quad \text{и т.д.}$$

Последние два равенства верны и в случае, когда среди последних сингулярных чисел есть нулевые. С учетом этих равенств:

$$A X A = U \Sigma V^T U^T V \Sigma^+ U^T U \Sigma V^T = U \Sigma \Sigma^+ U^T = U I U^T = A;$$
$$X A X = V \Sigma^+ U^T U \Sigma V^T V \Sigma^+ U^T = V \Sigma^+ \Sigma U^T = V I U^T = X;$$

Матрицы $A X$ и $X A$ — симметричные. Для $m < n$ аналогично.

Пусть $A \rightarrow a_{ij}$, $A^+ \rightarrow A_{ij}^+$, $U \rightarrow u_{ij}$, $V \rightarrow v_{ij}$ — элементы. Тогда:

$$a_{ij} = \sum_{k=1}^n \sigma_k u_{ik} v_{jk}, \quad a_{ij}^+ = \sum_{k \neq 0} \frac{v_{ik} u_{jk}}{\sigma_k}$$

Эффективная псевдообратная матрица A_ϵ^+ уменьшает число обусловленности, повышая надёжность результатов:

$$\sigma_\epsilon^+ = \begin{cases} \frac{1}{\sigma}, & \text{если } \sigma > \epsilon \\ 0, & \text{в противном случае} \end{cases}$$
$$a_{ij}^+(\epsilon) = \sum_{\sigma_k > \epsilon} \frac{v_{ik} u_{jk}}{\sigma_k}$$

Эффективная псевдообратная матрица удовлетворяет трём последним условиям, а первое выполняется с точностью до ϵ : $\|A X A - A\| \leq \epsilon$
Для ненулевого значения ϵ X может оказаться неединственной, удовлетворяющей этим 4 условиям. Но матрица с такими элементами дополнительно обладает наименьшей нормой.

Любой одношаговый итерационный метод для системы $Ax = b$ можно записать в виде $B_{n+1} \frac{x_{n+1} - x_n}{\tau_{n+1}} + A x_n = b$ где x_n — текущее приближение, x_{n+1} — следующее, B_{n+1} — матрица, задающая структуру метода, τ_{n+1} — шаг (или параметр релаксации) на шаге $n + 1$
По выбору B_{n+1} и τ_{n+1} различают: **явные** ($B_{n+1} = E$) и **неявные** ($B_{n+1} \neq E$), **стационарные** ($B_{n+1} = \text{const}$, $\tau_{n+1} = \text{const}$) и **нестационарные** (τ_{n+1} и/или B_{n+1} меняются)
D - диагональная, A_1 - левая треугольная, A_2 - левая треугольная
Примеры:
1. **Метод простой итерации** - $B_{n+1} = E$, $\tau_{n+1} = \tau = \text{const}$ Итерация: $x_{n+1} = (E - \tau A) x_n + \tau b$ условие сходимости: $0 < \tau < 2 \lambda_{\min}(A)$
2. **Итерационный метод Рундара** $B_{n+1} = E$, но τ_{n+1} меняется от итерации к итерации
Итерация: $x_{n+1} = x_n + \tau_{n+1} (b - A x_n)$ Оптимальный подбор τ_{n+1} (например, на основе полиномов Чебышева) ускоряет сходимость.
3. **Метод Якоби** Разложение $A = D + L + U$, где D — диагональная часть, L — нижняя треугольная, U — верхняя $B_{n+1} = D$, $\tau_{n+1} = 1$ Итерация: $x_{n+1} = D^{-1} (b - (L + U) x_n)$
4. **Метод Гаусса-Зейделя** $B_{n+1} = D + L$, $\tau_{n+1} = 1$ Итерация: $x_{n+1} = -(D + L)^{-1} U x_n + (D + L)^{-1} b$ При вычислении $x_{n+1}^{(j)}$ используются уже обновлённые $x_{n+1}^{(j)}$ для $j < k$
5. **Метод верхней релаксации (SOR)** $B_{n+1} = D + \omega L$, $\tau_{n+1} = \omega$, где $0 < \omega < 2$ При $\omega = 1$ метод совпадает с методом Гаусса-Зейделя